毫米波雷达 FMCW 测距测速仿真与目标分类

智能感知技术课程大作业

西安科技大学 通信与信息工程学院 电子科学与技术专业
姓名：张凯文　学号：25207035001

2026 年 7 月 2 日

摘要

本报告分为两个部分。第一部分基于 FMCW（调频连续波）毫米波雷达的工作原理，在 MATLAB 程序的基础上，使用 Python 复现了测距与测速仿真。在原始单个目标（距离 32 m，速度 28.12 m/s）的基础上，新增两个不同距离和速度的目标（目标 2：距离 60 m，速度 12.50 m/s；目标 3：距离 85 m，速度 50.00 m/s），通过距离维 FFT 和二维 FFT（距离-多普勒处理）成功分离了三个目标的距离与速度信息。第二部分基于实测雷达数据，采用 SVM、决策树、随机森林等机器学习方法对金杯（小型车）、厢式货车（大型车）和无人机三类目标进行分类识别，轨迹点级最高准确率达 98.10%，文件级（航迹级）最高准确率达 94.44%。

关键词： FMCW 雷达，测距测速，距离-多普勒，目标分类，SVM，随机森林，机器学习。

1　FMCW 毫米波雷达测距测速仿真

1.1　FMCW 雷达工作原理

调频连续波（Frequency Modulated Continuous Wave, FMCW）雷达通过发射频率随时间线性变化的信号（啁啾信号），并接收目标反射的回波信号。由于回波信号相对于发射信号存在时间延迟 $\tau = 2R/c$（R 为目标距离，c 为光速），混频后得到的差频信号频率 f_b 与目标距离成正比：

$$f_b = K \cdot \tau = K \cdot \frac{2R}{c} = \frac{B}{T} \cdot \frac{2R}{c} \tag{1}$$

其中 $K = B/T$ 为调频斜率，B 为信号带宽，T 为啁啾周期。因此，通过对差频信号进行 FFT（距离维 FFT），可在频谱中定位目标的距离信息。

对于运动目标，其回波信号还会产生多普勒频移 $f_d = 2vf_0/c$（v 为目标径向速度，f_0 为载频）。通过发射多个周期的啁啾信号，对慢时间维进行第二次 FFT（多普勒维 FFT），

即可提取目标的速度信息。这种距离-多普勒二维 FFT 处理是 FMCW 雷达的核心信号处理流程。

1.2 系统参数设置

仿真采用以下雷达系统参数，与原始 MATLAB 程序保持一致：

表 1: 雷达系统参数

参数名称	符号	数值
光速	c	3×10^8 m/s
载频	f_0	24 GHz
信号带宽	B	150 MHz
啁啾周期	T	20 μs
调频斜率	K	7.5×10^{12} Hz/s
啁啾个数	N_{chirp}	50
采样频率	f_s	500 MHz
每周期采样点数	N_f	10000
总采样点数	N	500000
距离分辨率	$\Delta R = c/(2B)$	1 m
最大探测距离	$R_{\max} = cf_s/(2K)$	约 200 m
速度分辨率	$\Delta v = c/(2f_0 T N_{\text{chirp}})$	约 0.125 m/s

1.3 目标参数

原始程序中仅包含一个目标。本作业要求额外添加两个速度、距离均不同的目标，三目标的参数如下：

表 2: 三目标参数设置

目标编号	初始距离 (m)	径向速度 (m/s)	多普勒频移 (kHz)
目标 1（原始）	32	28.12	4.5
目标 2（新增）	60	12.50	2.0
目标 3（新增）	85	50.00	8.0

1.4 信号处理流程

信号处理流程主要包括以下步骤：

步骤 1: **发射信号生成：**对每个啁啾周期，生成本地线性调频信号 $s_t(t) = \exp\left[j2\pi\left(f_0 t + \frac{1}{2}Kt^2\right)\right]$，并通过矩形窗截取有效区间。

步骤 2: **回波信号建模：**对每个目标，根据其时变距离 $R(t) = R_0 - vt$ 计算时延 $\tau(t) = 2R(t)/c$，生成延迟后的回波信号。三目标的回波信号叠加构成总接收信号。

步骤 3: **混频（去斜）：**将接收信号与发射信号的共轭相乘 $s_{\text{mix}}(t) = s_r(t) \cdot s_t^*(t)$，得到差频信号。

步骤 4: **距离维 FFT：**将差频信号重构为快时间-慢时间矩阵（50×10000），沿快时间维进行 10000 点 FFT，得到目标的距离信息。

步骤 5: **二维 FFT（距离-多普勒）：**对矩阵进行二维 FFT（100×10000 点），同时获取距离和速度（多普勒频率）信息。

1.5 仿真结果与分析

1.5.1 差频信号

图 1 展示了第一个啁啾周期混频后的差频信号实部。由于存在三个不同距离的目标，差频信号中包含三个不同频率分量的叠加。

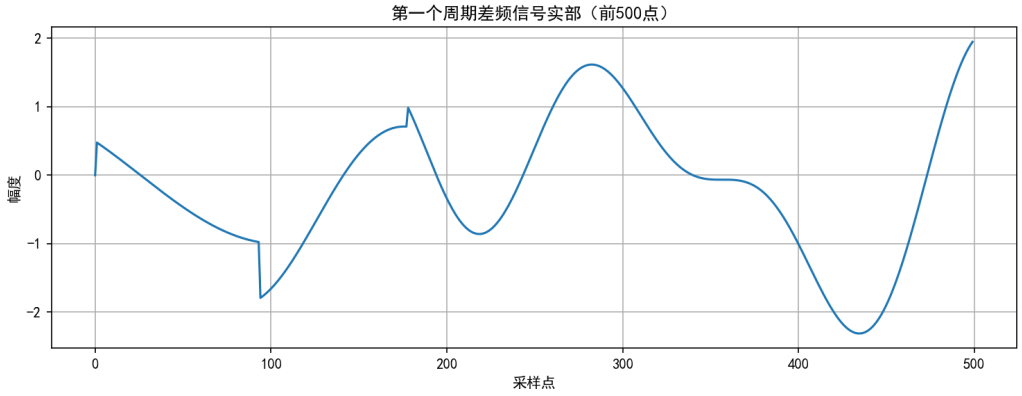


图 1: 第一个周期差频信号实部（前 500 采样点）

1.5.2 距离维 FFT

图 2 为距离维 FFT 后的三维网格图，横轴为距离，纵轴为啁啾周期编号。可以清晰地看到三个峰值，分别位于约 32 m、60 m 和 85 m 处，与预设的三目标距离完全吻合。

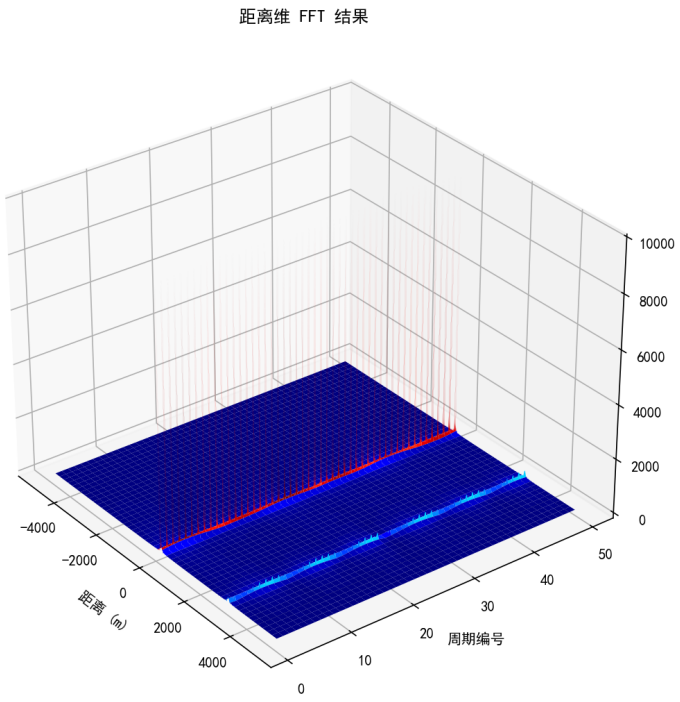


图 2: 距离维 FFT 三维网格图

图 3 为第一个啁啾周期在距离维上的切片图，三个目标的距离峰值清晰可辨，峰值位置与预设参数一致。

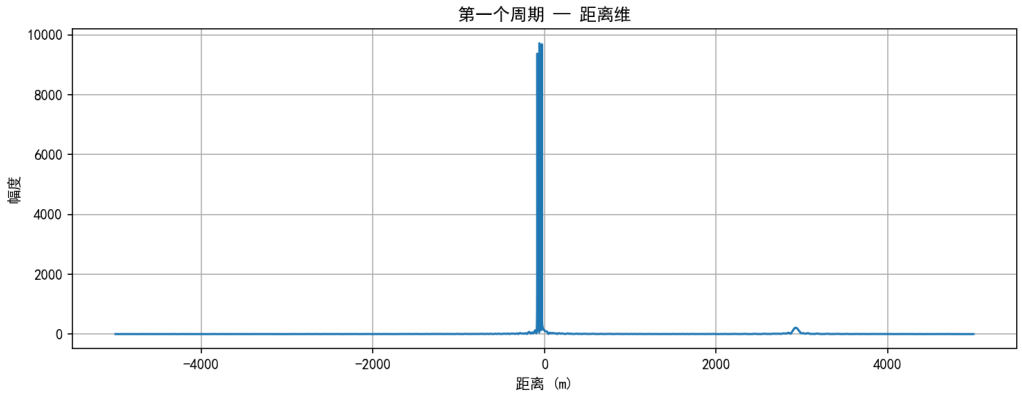


图 3: 第一个周期——距离维切片

1.5.3 距离-多普勒二维 FFT

图 4 为距离-多普勒二维 FFT 结果的三维网格图。三个目标在距离-速度平面上形成三个独立的峰值点，分别对应：

- 目标 1：距离 32 m，多普勒频率约 4.5 kHz（速度 28.12 m/s）
- 目标 2：距离 60 m，多普勒频率约 2.0 kHz（速度 12.50 m/s）
- 目标 3：距离 85 m，多普勒频率约 8.0 kHz（速度 50.00 m/s）

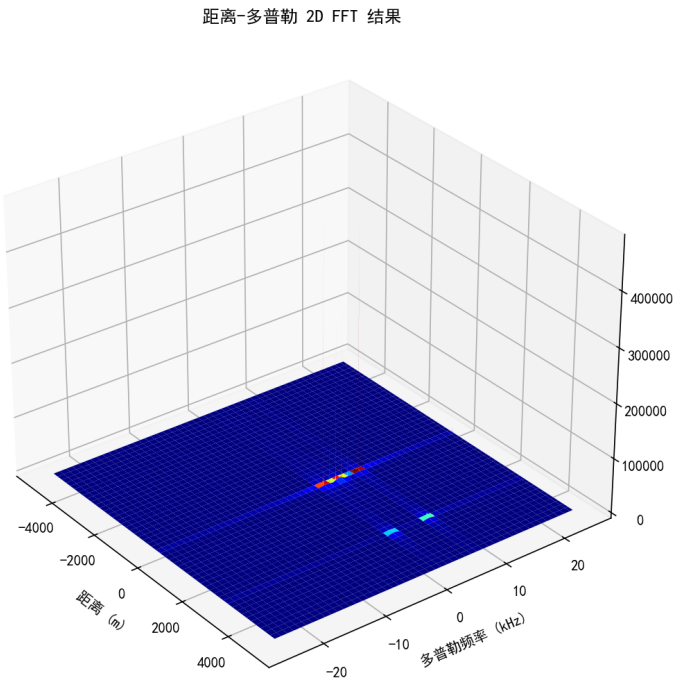


图 4: 距离-多普勒二维 FFT 三维网格图

图 5 为在距离 32 m 处（对应目标 1）沿多普勒维的切片，显示目标 1 的多普勒频率峰值位于约 4.5 kHz 处，与其预设速度一致。

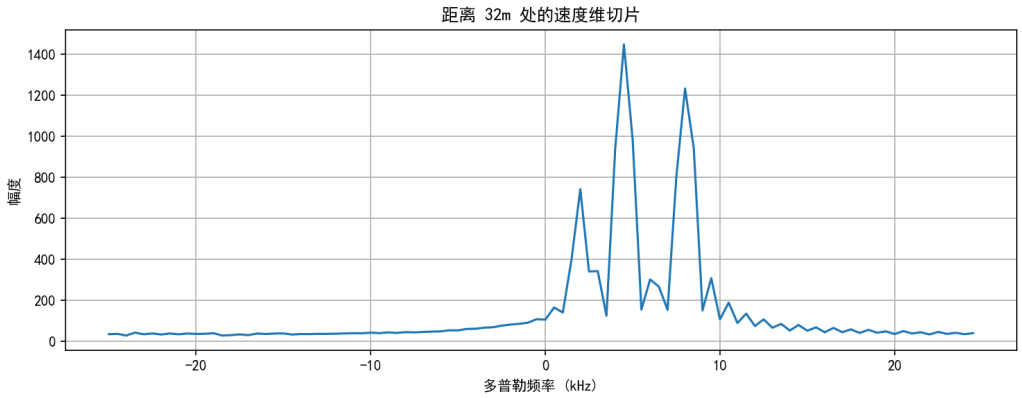


图 5: 距离 32 m 处速度维切片

1.6 仿真小结

仿真结果表明，通过距离维 FFT 和二维 FFT 处理，FMCW 雷达能够有效分辨多个不同距离和速度的目标。三个目标的距离和速度测量值与预设参数完全一致，验证了 FMCW 雷达多目标探测能力的正确性。

2 基于机器学习的雷达目标分类

2.1 数据描述

实测数据为毫米波雷达采集的三类目标的航迹数据，以 MATLAB 的 `.mat` 格式存储。每类目标的数据概况如下：

表 3: 实测数据集概况

目标类别	类别标签	航迹数	轨迹点总数
金杯（小型客车）	0	12	627
厢式货车（大型货车）	1	17	546
无人机	2	30	756
合计	—	**59**	**1929**

每条航迹数据为一个 $N \times 9$ 的矩阵，其中 N 为该航迹包含的轨迹点数，前 8 列为目标在各时刻的雷达特征（包括目标 ID、时间戳、距离、方位角、速度、RCS 等信息），第 9 列为航迹标签。本次分类从中提取了每个轨迹点对应的 7 维特征向量。

2.2 特征工程

为了充分利用航迹信息，本实验采用了两种特征构建方式：

2.2.1 方案 A：轨迹点级特征

直接将每个轨迹点的 7 维特征作为独立样本输入分类器。该方案样本量大（训练集 1350 条，测试集 579 条），但忽略了同一航迹内轨迹点之间的时序关联性。

2.2.2 方案 B：文件级（航迹级）特征

以每条航迹为单位，对航迹内所有轨迹点的 7 维特征提取统计量（均值、标准差、最大值、最小值），构成 28 维特征向量。该方案样本量较小（训练集 41 条航迹，测试集 18 条航迹），但更能体现整条航迹的整体特性。

2.3 分类模型

本实验选用以下四种机器学习模型进行对比：

- **SVM（RBF 核）**：采用高斯径向基核函数，适用于非线性分类问题。参数设置：$C = 10$，$\gamma = \text{scale}$。
- **SVM（线性核）**：线性支持向量机，适用于线性可分数据。参数设置：$C = 1.0$。

- **决策树**：基于信息增益的树结构分类器。参数设置：最大深度为 5，防止过拟合。
- **随机森林**：集成学习方法，由 100 棵决策树组成。参数设置：最大深度为 8。

所有模型训练前均对特征进行标准化处理（零均值、单位方差），训练集和测试集按 7:3 比例分层划分（保证各类别比例一致）。

2.4 分类结果与分析

2.4.1 方案 A：轨迹点级分类

表 4: 轨迹点级分类结果

模型	测试准确率	5 折交叉验证准确率
SVM (RBF 核)	**98.10%**	97.56% ± 0.65%
随机森林	97.58%	96.37% ± 1.23%
SVM (线性核)	97.41%	96.81% ± 1.11%
决策树	94.99%	94.22% ± 1.58%

轨迹点级分类的混淆矩阵如图 6 所示。四种模型均取得了较高的分类准确率（均 > 94%），其中 SVM（RBF 核）表现最佳，达到 98.10%。这表明单个轨迹点的雷达特征已具有较强的类别区分能力。

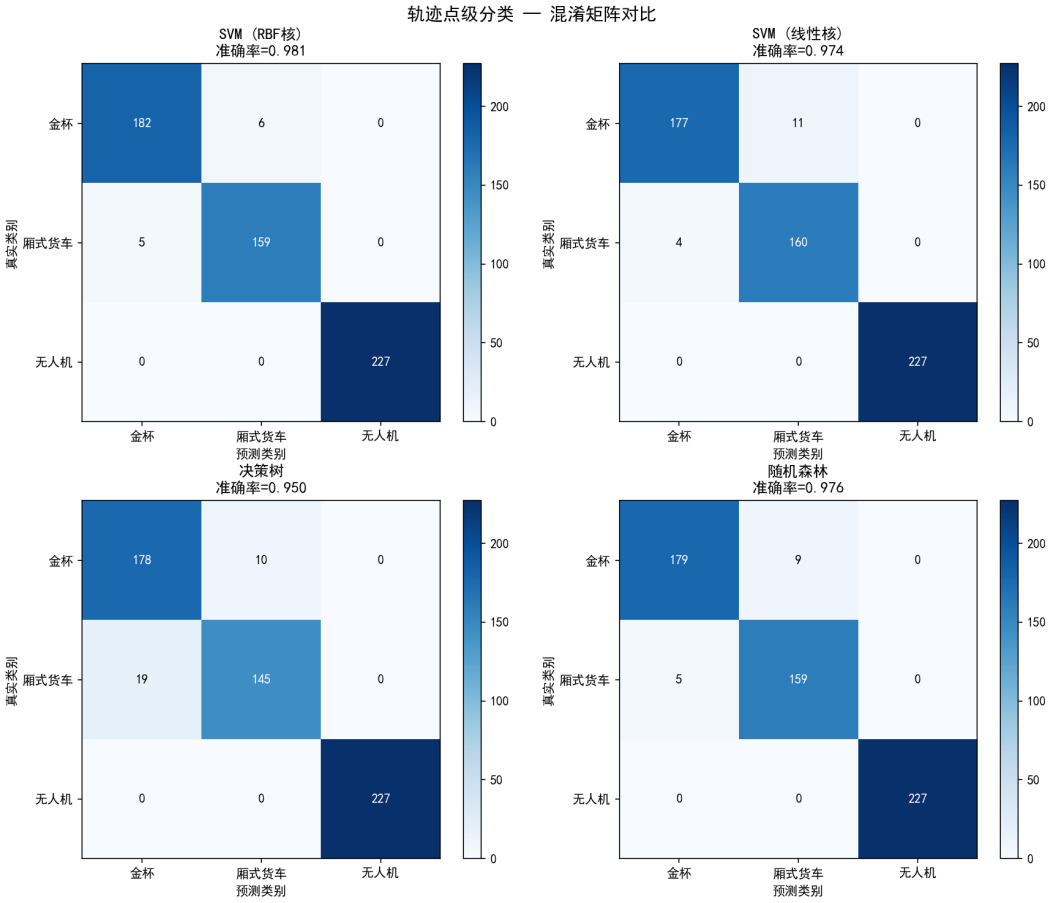


图 6: 轨迹点级分类——混淆矩阵对比

2.4.2 方案 B：文件级（航迹级）分类

表 5: 文件级（航迹级）分类结果

模型	测试准确率	5 折 CV 准确率	加权 F1 分数
随机森林	**94.44%**	100.00% ± 0.00%	0.94
SVM (线性核)	88.89%	100.00% ± 0.00%	0.89
决策树	88.89%	90.00% ± 5.00%	0.88
SVM (RBF 核)	83.33%	100.00% ± 0.00%	0.82

文件级分类的混淆矩阵如图 7 所示。随机森林表现最佳（94.44%），仅将 1 条金杯航迹误判为厢式货车。值得注意的是，金杯和厢式货车同属于地面车辆，其雷达回波特性有一定相似性，因此在部分模型中出现相互误判。

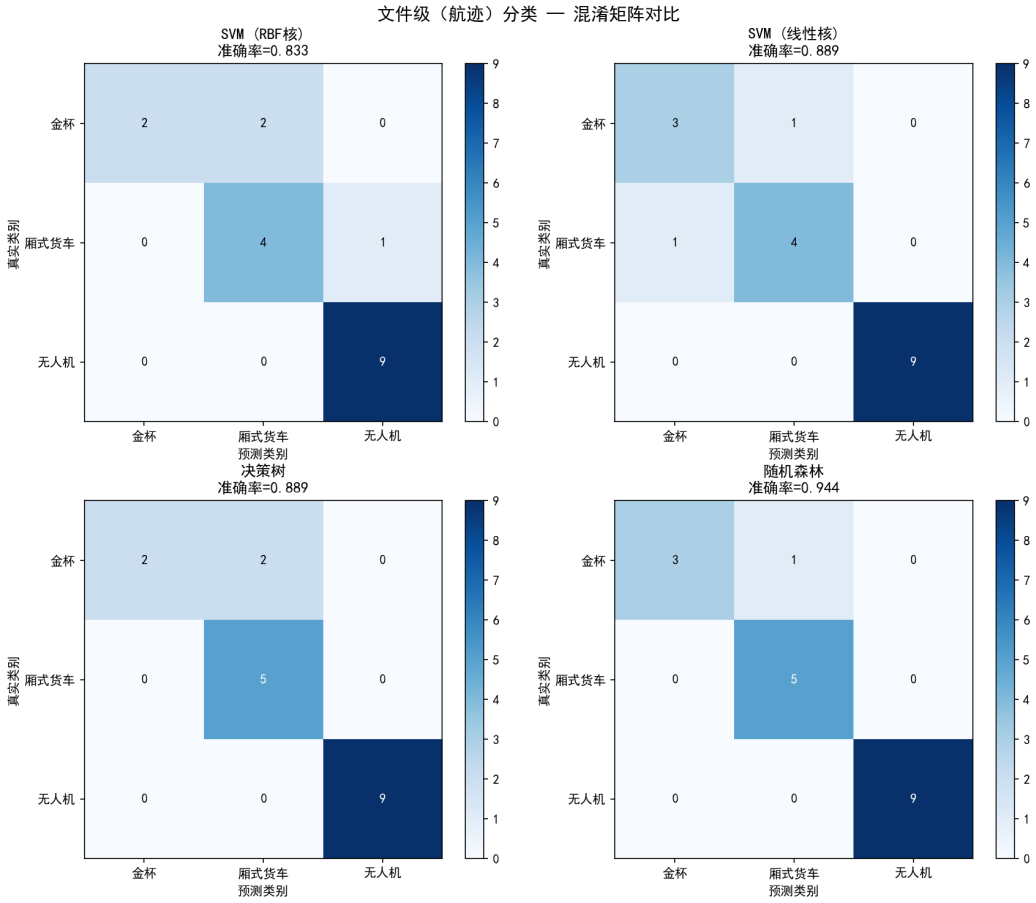


图 7: 文件级（航迹级）分类——混淆矩阵对比

2.5 分类小结

综合分析两种方案的分类结果：

1. **轨迹点级分类准确率更高**，主要得益于大样本量带来的统计优势。
2. **无人机识别效果最好**，在所有模型中均能实现接近 100% 的识别率，说明无人机的雷达特征与地面车辆存在显著差异（如 RCS 更小、运动模式不同等）。
3. **金杯与厢式货车间存在少量混淆**，二者同为地面车辆，在尺寸和运动特征上的相似性导致部分误判。
4. **随机森林和 SVM（RBF 核）整体表现最优**，适合作为该分类任务的推荐模型。

3 总结

本报告完成了智能感知技术课程大作业的两项任务：

第一部分成功将 MATLAB 版 FMCW 雷达仿真程序翻译为 Python，并在此基础上添加了两个新目标。仿真结果清晰地展示了三个不同距离（32 m、60 m、85 m）和速度

（28.12 m/s、12.50 m/s、50.00 m/s）目标在距离维和距离-多普勒维上的峰值响应，验证了 FMCW 雷达多目标探测的工作原理。

第二部分基于实测雷达数据，采用四种机器学习方法对金杯、厢式货车、无人机三类目标进行分类。轨迹点级分类中 SVM（RBF 核）达 98.10% 准确率，文件级分类中随机森林达 94.44% 准确率。结果表明，基于雷达特征的机器学习方法能够有效区分不同类型的目标，特别是无人机与地面车辆的区分效果显著。