电子测量技术与人工智能的融合研究

——机器学习、深度学习与强化学习的应用

作　者： 张凯文

学　号： 25207035001

专　业： 电子科学与技术

学　院： 通信与信息工程学院

学　校： 西安科技大学

2026 年 6 月

摘　要

电子测量技术是现代科学技术的重要基础，在工业制造、通信、医疗健康、环境监测等领域发挥着不可替代的作用。然而，传统的电子测量方法在面对日益复杂的测量对象和不断提高的精度要求时，逐渐暴露出适应性不足、智能化水平有限等问题。与此同时，以机器学习、深度学习和强化学习为代表的人工智能技术取得了革命性突破，为电子测量技术的智能化升级提供了全新的技术手段。

本文系统综述了电子测量技术与人工智能的融合研究进展。首先介绍了电子测量技术的基本体系与现代测量面临的挑战，概述了机器学习、深度学习和强化学习的核心思想；然后分别从信号处理与特征提取、误差补偿与故障诊断、信号识别与时序分析、自适应测量优化、传感器网络调度等多个维度，阐述了三种人工智能技术与电子测量的融合路径；最后通过工业过程测量、医疗电子诊断、环境监测和通信信号测量等综合应用案例，展示了智能电子测量技术的实际效果，并对未来发展趋势进行了展望。

关键词：电子测量；人工智能；机器学习；深度学习；强化学习；信号处理；智能传感器；故障诊断

1 引言

1.1 研究背景与意义

电子测量技术是现代科学技术体系中最为基础的支撑技术之一。从半导体器件参数测试到雷达系统性能评估，从消费电子质量检测到国防装备精密校准，电子测量贯穿于现代工业生产和科学研究的每一个环节。其核心任务是将被测物理量转化为可处理的电信号，并从中提取有价值的信息。

随着信息时代的深入发展，电子测量面临着前所未有的挑战。被测对象的复杂性急剧增加——现代通信信号的调制带宽已达数 GHz，精密制造的尺寸要求达到纳米量级。测量环境的复杂性也在不断提升——工业现场存在大量电磁干扰和机械振动，医疗测量需要在保证舒适度的同时获取准确的生理信号。传统的基于固定数学模型和预设规则的方法越来越难以满足需求。

人工智能技术的蓬勃发展为电子测量带来了全新的契机。机器学习能从大量数据中自动学习内在规律；深度学习通过多层神经网络提取信号中的高层抽象特征；强化学习则能通过与环境的持续交互，自主学习最优的测量策略。电子测量技术与人工智能的融合，意味着测量系统从被动的数据采集工具，转变为具有感知、学习和决策能力的智能系统。这对于推动工业 4.0、智能制造、精准医疗等领域具有深远意义。

1.2 国内外研究现状

近年来，国内外对人工智能与电子测量的融合展开了广泛研究。国际上，MIT、斯坦福等高校在智能传感器和自适应测量方面取得了显著成果。德国工业 4.0 将智能测量列为核心技术，西门子等企业已将机器学习集成到工业测量仪器中。在国内，清华大学、浙江大学、西安电子科技大学等高校也在智能仪器和测量信号智能处理领域形成了有影响力的研究团队。

在机器学习方面，支持向量机（SVM）被广泛用于故障诊断，随机森林和 XGBoost 在传感器数据分析中取得成功应用。在深度学习方面，卷积神经网络（CNN）在电磁信号识别和工业视觉检测中取得突破，长短期记忆网络（LSTM）在时序测量数据建模中表现出色，自编码器被用于信号去噪和异常检测。在强化学习方面，深度 Q 网络（DQN）和深度确定性策略梯度（DDPG）等算法被应用于自适应测量参数优化和传感器网络资源调度。

尽管取得了诸多进展，当前研究仍存在不足：大部分研究集中于单一 AI 技术与特

定场景的结合，缺乏系统层面的融合框架；深度学习模型的可解释性问题尚未充分解决；强化学习在电子测量中的应用仍处于起步阶段。

1.3 本文主要工作与章节安排

本文以电子测量技术与人工智能的融合为研究主题，聚焦机器学习、深度学习和强化学习三大核心技术，系统阐述其与电子测量结合的理论基础、关键技术和应用场景。本文共分八章：第 1 章引言，第 2 章电子测量技术基础，第 3 章人工智能技术概述，第 4 章至第 6 章分别论述三种 AI 技术与电子测量的融合，第 7 章展示综合应用案例，第 8 章分析挑战与未来趋势并总结全文。

2 电子测量技术基础

2.1 电子测量技术概述

电子测量技术是利用电子学原理和电子技术手段，对电学量和非电学量进行测量的一门综合性技术。其基本思想是将被测物理量通过传感器转换为电信号，然后对电信号进行调理、采集、处理和分析，最终得到被测物理量的数值表征。

电子测量技术具有以下显著特点：第一，频率范围极宽，从直流到太赫兹频段均可覆盖，这使得电子测量能够应用于从生物电信号（毫赫兹级）到微波通信信号（吉赫兹级）的广泛场景。第二，精度极高，现代电子测量仪器可以实现百万分之一乃至更高精度的测量。第三，速度快，可以实现纳秒级甚至皮秒级的瞬态信号捕捉。第四，易于实现自动化和远程化，电子测量系统可以方便地与计算机和网络连接。第五，可测量参数种类繁多，包括电压、电流、功率、频率、相位、阻抗等数十种基本电参数，以及温度、压力、位移、速度、加速度等通过传感器转换的非电量参数。

现代电子测量技术已经形成了一套完整的体系。在理论层面，涵盖了测量误差理论、信号与系统理论、随机信号分析和参数估计等；在技术层面，包括传感器技术、信号调理技术、模数转换技术、数字信号处理技术和虚拟仪器技术等；在应用层面，覆盖了电子元器件测试、通信系统测试、电磁兼容测试、生物医学测量、工业过程测量和环境监测等众多领域。

2.2 现代电子测量系统的组成

一个完整的现代电子测量系统通常由以下核心部分组成：

传感器/换能器：负责将被测物理量转换为电信号，其性能在很大程度上决定了整个系统的精度和可靠性。

信号调理电路：对传感器输出的原始信号进行放大、滤波等预处理，使其满足后续采集的要求。

数据采集系统：将模拟信号转换为数字信号，核心是模数转换器（ADC），关键指标包括分辨率和采样率。

数字信号处理单元：对数字信号进行各种数学运算和分析，如数字滤波、频谱分析、时频分析等。

控制与通信接口：负责协调各部分工作，实现数据交换。常用接口包括 USB、Ethernet、Wi-Fi 等。

软件与算法层：负责实现测量算法、数据处理和用户交互，是测量系统的”大脑”。

2.3 电子测量面临的主要挑战

尽管电子测量技术已取得了巨大进步，仍面临一系列关键挑战：

复杂环境下的精度保障。工业现场的温度变化、电磁干扰、机械振动等因素会导致传感器特性漂移和信号噪声增加，严重降低测量精度。

高维异构数据的融合处理。现代复杂系统往往需要同时采集数十甚至数百个不同物理量的测量数据，如何有效融合这些多源异构数据是一个难题。

非线性与非高斯信号的处理。实际测量中的许多信号表现出明显的非线性和非高斯特性，传统的线性处理方法难以胜任。

实时性与计算资源的矛盾。高性能信号处理算法需要大量计算资源，而嵌入式测量设备的计算能力有限。

测量系统的自适应与智能化。传统测量系统缺乏对测量对象和环境变化的适应能力，无法根据实际情况自主调整测量策略。

海量测量数据的深度利用。物联网时代每天产生海量测量数据，但目前缺乏对这些数据的深度挖掘和利用。

这些挑战恰好是人工智能可以发挥关键作用的领域：数据驱动建模应对非线性关系，层次化特征提取处理高维数据，自适应决策实现智能化调整。

2.4 电子测量技术的智能化演进趋势

电子测量技术正从自动化向智能化跃迁。智能化电子测量的关键特征包括：感知智能化——传感器能对自身状态进行实时评估；处理智能化——根据信号特性自适应选择最优处理方法；决策智能化——基于不完整信息做出合理决策；交互智能化——以自然方式与人类和其他系统协同工作。

从技术架构看，智能化电子测量系统可划分为感知层、边缘计算层和云端智能层，形成”云-边-端”协同的分层智能架构。

3 人工智能技术概述

3.1 机器学习基础

机器学习是人工智能的核心分支，研究如何让计算机利用数据来改善性能。Arthur Samuel 在 1959 年将机器学习定义为" 赋予计算机在没有明确编程的情况下学习的能力"。从学习范式的角度，主要分为以下三类：

监督学习：从带有标签的训练数据中学习输入到输出的映射关系。以故障诊断为例，我们收集大量已标注故障类型的传感器数据（标签告诉我们" 这段振动信号对应轴承磨损"），训练模型学会从新的传感器数据中自动判断故障类型。常用算法包括线性回归、逻辑回归、支持向量机（SVM）、决策树、随机森林、梯度提升树和 K 近邻（KNN）等。在电子测量中，监督学习广泛用于故障类型识别、测量误差预测和异常检测等任务。

无监督学习：从无标签数据中发现隐藏的结构和模式。例如，面对大量未标注的传感器运行数据，无监督学习可以自动将相似的数据聚在一起，帮助我们发现不同的运行工况或潜在的故障模式。常用算法包括 K-means 聚类、主成分分析（PCA）、独立成分分析（ICA）等。在电子测量中，无监督学习可用于聚类分析、特征降维和模式发现，特别适合缺乏标注数据的场景。

强化学习：研究智能体如何在与环境的交互中学习最优决策策略。智能体通过试错获得奖励信号来学习——做对了获得奖励，做错了受到惩罚。这与监督学习中" 正确答案" 预先已知有本质区别。例如，一个智能测量系统可以通过不断尝试不同的采样率，观察每次测量精度和功耗的反馈，最终学会在什么情况下选择什么采样率最好。强化学习将在第 3.3 节详细论述。

机器学习的核心概念包括模型容量（模型的学习能力）、偏差-方差权衡（简单模型可能欠拟合，复杂模型可能过拟合）和泛化能力——即模型在未见过的新数据上也能保持良好性能。一个好的模型需要在拟合能力和泛化能力之间取得平衡，这正是机器学习研究和实践中最核心的考量。

3.2 深度学习技术

深度学习使用多层神经网络来学习数据的层次化表示。其核心优势在于：通过逐层抽象，网络能够自动从原始数据中提取从低层到高层的特征，无需人工设计特征。

卷积神经网络（CNN）：专门处理网格结构数据（如图像、时频图）。CNN 通过卷积核提取局部特征，通过池化层增强平移不变性。经典架构包括 AlexNet、VGGNet、

ResNet 等。ResNet 引入残差连接解决了深层网络的退化问题，使训练超百层网络成为可能。在电子测量中，CNN 广泛用于信号调制识别、工业视觉检测和声学信号分析。

循环神经网络（RNN）：专门处理序列数据，具有”记忆”能力。长短期记忆网络（LSTM）通过门控机制解决了标准 RNN 难以学习长期依赖的问题。门控循环单元（GRU）是 LSTM 的简化版，在保持相当性能的同时减少了计算量。在电子测量中，RNN 特别适合处理传感器时序信号的分析与预测。

自编码器（Autoencoder）：一种无监督学习网络，目标是学习输入数据的压缩表示并从中重建输入。去噪自编码器（DAE）可用于测量信号降噪，变分自编码器（VAE）可用于异常检测。

生成对抗网络（GAN）：由生成器和判别器组成，通过对抗训练使生成器学习真实数据分布。在电子测量中可用于数据增强（解决稀缺样本问题）和缺失数据补全。

Transformer 与注意力机制：基于自注意力机制完全摒弃循环结构，实现并行处理。自注意力能捕捉序列中任意位置之间的全局依赖关系。在电子测量领域，Transformer 正被越来越多地应用于电磁信号分析和多传感器数据融合。

3.3 强化学习技术

强化学习研究智能体如何在环境中通过试错学习最优策略，以最大化累积奖励。其数学框架是马尔可夫决策过程（MDP）。

MDP 的核心要素包括：状态空间（描述环境的所有可能情况）、动作空间（智能体可执行的所有操作）、状态转移（执行动作后环境如何变化）、奖励函数（每个动作带来的即时反馈）和折扣因子（平衡当前与未来奖励的重要性）。智能体的目标是学习最优策略，使从任意状态出发的期望累积奖励最大化。

强化学习算法主要分为三类：

基于价值的方法：学习每个状态-动作对的”价值”，选择价值最高的动作。代表算法是 Q-Learning 和深度 Q 网络（DQN）。DQN 使用深度神经网络来估计价值函数，通过经验回放和目标网络稳定训练。

基于策略的方法：直接学习策略函数（给定状态，输出各动作的概率），通过优化策略参数来最大化奖励。

深度强化学习：将深度学习的表示能力与强化学习的决策能力结合。代表性算法包括：深度确定性策略梯度（DDPG，适用于连续动作）、近端策略优化（PPO，训练稳定）、软演员-评论家（SAC，探索效率高）。

4 机器学习与电子测量的融合

4.1 信号处理与特征提取

信号处理是电子测量的核心环节，特征提取则是连接原始信号与高层决策的桥梁。传统方法依赖于对信号物理机制的精确建模，在非线性、非平稳场景下往往力不从心。

核方法与降维。核主成分分析（KPCA）通过核技巧将数据映射到高维空间后再进行主成分分析，能有效捕捉测量数据中的非线性结构。独立成分分析（ICA）假设观测信号是若干独立源信号的混合，可从混合信号中分离出原始独立源，特别适用于多通道测量信号的盲源分离，如从脑电图中分离不同脑区的神经活动。

流形学习。流形学习假设高维测量数据分布在某个低维流形上。代表性算法包括 t-SNE 和等距映射（Isomap）。这些方法可以揭示测量数据背后的内在物理规律，例如从大量电路测试参数中发现器件的退化轨迹。

集成学习用于特征选择。随机森林和梯度提升树不仅可用于分类回归，其内置的特征重要性评估机制也是有效的特征选择工具，能从大量候选特征中自动筛选最有价值的特征子集。

4.2 测量误差补偿与智能校准

测量误差可分为系统误差（有规律，如零点漂移、非线性失真）、随机误差（服从统计规律）和粗大误差（操作失误或突发干扰产生）。传统方法在面对多因素耦合误差时效果有限。

基于支持向量回归（SVR）的误差建模。SVR 通过引入不敏感损失函数，在容忍小误差的前提下寻找最优回归曲线，能有效建立环境因素（温度、湿度等）与测量误差之间的非线性映射模型。例如，在电压测量中利用 SVR 建立温度-误差模型，可在宽温度范围将误差降低一个数量级。

基于高斯过程（GP）的不确定度量化。高斯过程不仅能给出预测值，还能给出预测的置信区间。这在需要严格控制风险的场合（如航空航天、医疗诊断）尤为重要——不仅能补偿误差，还能告知每次测量的可信程度。

基于集成学习的协同补偿。在多传感器系统中，随机森林或梯度提升树可同时处理多个输入变量，自动学习复杂的误差耦合模式，无需深入了解误差机理。

4.3 故障诊断与预测性维护

基于一类 SVM 的异常检测。一类支持向量机学习正常数据的边界，将超出边界的数据标记为异常。在仅有正常运行数据的情况下即可建立传感器正常行为模型，特别适合故障样本稀少的场景。

基于随机森林的故障分类。从测量信号中提取时域特征（均值、方差、峰值等）、频域特征（各频段能量等），构成特征向量输入随机森林分类器，可识别传感器偏置故障、增益故障、漂移故障等多种典型故障模式。

基于梯度提升树的寿命预测。XGBoost 和 LightGBM 等梯度提升树方法在结构化表格数据的回归任务中表现卓越，可从历史运行数据中提取退化趋势特征，预测关键部件的剩余使用寿命（RUL），支持从” 计划性维护” 向” 视情维护” 转变。

4.4 测量数据分类与回归

在电子测量的许多场景中，核心任务可自然地形式化为分类或回归问题。K 近邻（KNN）算法在信号调制识别中以较低计算复杂度实现高准确率。决策树将复杂的测量决策过程表示为一串可追踪的 if-then 规则，具有极强的可解释性。随机森林和梯度提升树等集成方法通过组合多个基学习器，能获得比任何单一模型更准确、更稳健的预测性能，在化工过程测量中实现产品质量的在线软测量。

5 深度学习与电子测量的融合

5.1 卷积神经网络在信号识别中的应用

卷积神经网络凭借强大的局部特征提取能力，已成为信号识别与分类领域最重要的深度学习工具之一。在电子测量中，CNN 的应用涵盖从一维时序信号到二维时频图像的广泛范围。

一维 CNN 在电磁信号识别中的应用。无线通信信号的自动调制识别是通信侦察和频谱管理的关键技术。传统方法依赖手工设计的特征（如高阶累积量、循环平稳特征等），需要大量的领域知识。一维 CNN 可直接以原始 I/Q 采样序列为输入，自动学习判别性特征，实现端到端的调制识别。典型的网络结构包括多个一维卷积层、批归一化层和池化层的堆叠，最后通过全连接层输出各类调制方式的概率。在低信噪比条件下，基于 CNN 的方法识别准确率可提升 10%-20%。

二维 CNN 在时频分析中的应用。许多测量信号的频域特性随时间变化。将一维信号通过短时傅里叶变换（STFT）或小波变换转换为二维时频图，再利用二维 CNN 分析，是一种非常有效的策略。在声学测量中，机器设备的运行声音包含了丰富的状态信息——将设备声音转换为梅尔频谱图后输入 CNN，可自动识别设备运行状态和故障类型。在电力设备局部放电检测中，将放电信号的时频图输入 CNN，能区分电晕放电、沿面放电等不同放电模式。

三维 CNN 在工业视觉测量中的应用。三维 CNN 通过在空间维度上同时进行卷积操作，能从立体视觉数据或视频序列中提取时空特征。在电子制造中的焊点质量检测、印刷电路板（PCB）缺陷检测等应用中，三维 CNN 可以从多角度图像中自动识别微小缺陷，检测精度和速度均超越传统图像处理方法。

轻量级 CNN 在嵌入式设备中的应用。在资源受限的嵌入式测量设备上部署 CNN 时，计算量和存储需求是关键限制因素。深度可分离卷积将标准卷积分解为逐通道和逐点两步，大幅减少计算量。MobileNet 等轻量级架构使得在微控制器或低功耗 FPGA 上部署 CNN 进行实时信号分析成为可能，推动了智能传感器的发展。

5.2 循环神经网络在时序分析中的应用

电子测量中的大量数据具有天然的时序特性：传感器持续输出的时间序列、设备运行参数的连续记录、电网负荷的实时监测数据等。循环神经网络及其变体专门为处理序列数据而设计，在时序测量数据分析中发挥着不可替代的作用。

LSTM 在传感器时序预测中的应用。长短期记忆网络通过精巧的门控机制——遗忘门决定丢弃哪些旧信息，输入门决定存储哪些新信息，输出门决定输出哪些信息——能在数百甚至上千个时间步的跨度上捕捉长期依赖关系。在工业应用中，基于 LSTM 的温度传感器趋势预测可在设备过热前数小时发出预警，为预防性维护赢得宝贵时间。例如，通过分析过去几个小时的温度变化趋势，LSTM 能预测未来半小时内是否会达到危险温度阈值。

双向 LSTM 在信号上下文分析中的应用。在许多测量分析任务中，某一个时间点的信号解读不仅取决于之前的历史，也取决于之后的未来信息。双向 LSTM（BiLSTM）同时从前向和后向处理序列，能利用完整上下文。在电力质量分析中，BiLSTM 可以从完整的电压/电流波形中更准确地识别暂态事件（如电压骤降、谐波畸变），准确率显著优于仅使用单向信息的模型。

注意力机制与可解释分析。将注意力机制与 RNN 结合，不仅可以提升模型性能，还能提供模型决策的可解释性。注意力权重指示了模型做出预测时关注了输入序列的哪些时间步。在机械振动分析中，注意力权重可以揭示哪些时间段的振动特征对于故障诊断最具有决定性作用，帮助工程师理解故障的物理机理。

Seq2Seq 架构在多步预测中的应用。序列到序列（Seq2Seq）架构由编码器 RNN 和解码器 RNN 组成，编码器将整个输入序列编码为上下文向量，解码器从中逐步生成输出序列。在电子测量中，Seq2Seq 架构适用于多步预测任务，如根据历史负荷数据预测未来 24 小时的电力负荷曲线，或根据前期反应条件预测整个化学反应过程的温度变化轨迹。

5.3 自编码器在信号去噪与重构中的应用

去噪自编码器（DAE）。DAE 的训练方式是先向干净信号加噪，再训练网络从含噪版本重建干净信号。与传统滤波器相比，DAE 不需要预先假设噪声统计特性，能处理复杂的、非高斯的噪声模式。在心电图（ECG）测量中，DAE 可同时抑制基线漂移、工频干扰和肌电噪声。

稀疏自编码器在压缩感知中的应用。压缩感知理论指出，如果信号在某个变换域是稀疏的，可用远低于传统采样率的速率采样后重建。稀疏自编码器可实现从压缩测量值到原始信号的一步式快速重构。

变分自编码器（VAE）在异常检测中的应用。仅在正常数据上训练的 VAE，对正常样本重构误差小，对异常样本重构误差大。重构误差可直接作为异常分数，在工业传感器网络中广泛用于检测传感器漂移和数据异常。

5.4 生成对抗网络与 Transformer

GAN 在数据增强中的应用。条件生成对抗网络（CGAN）可生成指定类别的合成样本，解决故障诊断中稀有故障样本不足的问题。CycleGAN 可实现测量域适应——将实验室数据转换为现场风格，提升模型在实际场景中的准确率。

Transformer 在测量领域的应用。Vision Transformer（ViT）在工业视觉检测中能同时关注局部细节和全局布局。时间序列 Transformer（如 Informer）通过改进注意力机制，可高效处理长达数千时间步的测量序列。跨模态 Transformer 能融合温度、振动、声学等多种传感器数据，实现对系统状态的全面评估。

6 强化学习与电子测量的融合

6.1 自适应测量策略优化

自适应测量是指系统根据当前测量结果和环境条件，动态调整测量参数，以在给定约束下获取最优测量效果。这与强化学习的序贯决策特性天然契合。

基于 DQN 的自适应采样率调整。当信号变化剧烈时需要高采样率，平稳时可以降低采样率以节省功耗。将自适应采样率选择建模为强化学习问题：状态包括当前信号统计特征和电池电量，动作为可选采样率，奖励兼顾重构精度和功耗。实验表明，基于 DQN 的自适应策略相比固定高采样率方案，可保持 98% 以上精度的同时节约约 40% 的功耗。

基于 DDPG 的连续参数优化。许多测量参数（放大器增益、滤波器截止频率等）是连续变量。DDPG 可在连续动作空间中优化策略，适用于连续测量参数的在线调整，在网络分析仪中可自动寻找测量速度与精度的最优平衡。

不确定性感知的决策。贝叶斯强化学习通过维护策略的后验分布来量化决策不确定性。当系统对决策不够确定时，可选择更保守的动作或主动探索以收集信息。这对医疗诊断测量等安全关键应用尤为重要。

6.2 智能传感器网络的资源调度

无线传感器网络（WSN）广泛应用于环境监测和工业物联网。传感器网络的资源调度——包括节点唤醒/睡眠、通信频道分配、路由选择等——本质上是复杂的大规模决策问题。

多智能体强化学习用于节点协同。将每个传感器节点视为独立智能体，基于局部观测做出决策，通过协作实现网络整体优化。基于 QMIX 或 MADDPG 的多智能体调度策略能在满足监测需求的前提下最大化网络生存周期。

自适应路由选择。将路由建模为强化学习问题：状态包含节点队列长度和链路质量，动作是选择下一跳节点。基于 DQN 的自适应路由能在网络拓扑动态变化时快速调整，表现优于传统路由协议。

传感器自适应唤醒。利用上下文赌博机算法，传感器节点学习在什么环境条件下应唤醒以获取最有价值的测量数据，在满足信息需求的前提下最小化能量消耗。

6.3 测量仪器的智能自动校准

基于强化学习的仪器自校准。高精度数字万用表内部包含多个相互耦合的可调参数，传统校准耗时且依赖人工。将校准建模为强化学习问题：状态为当前校准系数和误差统计，动作为系数调整方向和幅度，奖励为误差减小量。基于 PPO 的智能体可自主学习最优校准策略，大幅缩短校准时间并达到较高精度。

元强化学习用于跨仪器快速校准。不同型号仪器的校准特性不同。元强化学习通过在大量相似校准任务上训练，学习能快速适应新任务的初始策略。对新型号仪器，仅需少量试错即可找到接近最优的校准方案，将新仪器校准效率提升数倍。

6.4 多传感器协同测量的决策优化

基于 POMDP 的测量点序贯选择。部分可观测马尔可夫决策过程（POMDP）适用于状态不能完全观测的场景。在多传感器测量中，基于 POMDP 的序贯策略在每个步骤选择最优测量点以最大化信息增益。在晶圆测试中，自适应策略可选择性测量关键测试点，将测试时间缩短 30%-50%。

分层强化学习用于复杂测量任务。复杂测量任务可分解为子任务层次结构。分层强化学习引入高层策略（选择子任务）和低层策略（执行子任务），在航天器系统级测试中能自动分解测试流程并动态选择测试序列，显著提高测试效率和故障发现率。

7 综合应用案例分析

7.1 工业过程测量与智能控制

工业 4.0 时代的到来使得工业过程测量系统从简单的数据采集装置向智能化、网络化的综合测量与控制系统演进。以化工生产过程为例，一个典型的智能过程测量系统集成了温度、压力、流量、液位、pH 值和成分分析等数十种不同类型的传感器，以秒级甚至毫秒级的频率持续采集各工艺参数。

基于深度学习的软测量。在化工过程中，许多关键质量指标（如产品纯度、反应转化率）无法通过传感器直接在线测量，通常需要定时取样送实验室分析，存在数小时的测量延迟。软测量技术通过建立易测过程变量（温度、压力、流量等）与难测质量指标之间的数学模型，实现关键质量指标的实时在线估计。基于 LSTM-注意力机制的深度学习软测量模型可以从历史数据中自动学习复杂的非线性动态关系。在某炼油厂分馏塔产品干点预测中，该模型将预测均方根误差从传统 PLS 方法的 2.5°C 降低到了 0.8°C，实现了准确实时的在线质量估计。

基于强化学习的 PID 参数自整定。工业过程控制中的 PID 控制器参数整定是一项耗时且高度依赖经验的工作。基于深度强化学习的自适应 PID 参数优化方法能够在线学习最优的 PID 参数调整策略。强化学习智能体以当前控制误差、误差变化率和历史控制性能为状态，以 PID 三个参数（比例、积分、微分系数）的调整量为动作，以控制性能指标（如超调量、稳态误差）的改善为奖励。在某化工反应器的温度控制中，基于强化学习的自适应 PID 控制器相比固定参数 PID，将温度超调量降低了 40%，稳态误差减小了 60%，显著提升了产品质量的一致性。

基于集成学习的预测性维护。在工业旋转机械（泵、压缩机、风机等）的预测性维护中，基于 XGBoost 的集成学习模型被用于融合振动、温度、油液分析和运行参数等多源测量数据，预测设备的剩余使用寿命。系统首先从原始传感器数据中提取振动信号的时域特征（RMS、峰值、峭度等）、频域特征（各倍频能量等）和时频特征，然后训练梯度提升树模型输出 RUL 预测值。在某化工厂的离心泵预测性维护项目中，基于 XGBoost 的 RUL 预测模型在故障发生前 2-4 周即发出了预警，避免了非计划停机，每年节约维护成本数百万元。这种从”计划性维护”到”视情维护”的转变，是工业测量智能化的重要体现。

7.2 医疗电子测量与智能诊断

医疗电子测量技术直接关系到患者的健康和生命。心电图（ECG）、脑电图（EEG）、医学成像（CT、MRI、超声）等医疗电子测量技术每天产生海量的诊断数据，AI 技术正在深刻改变这些数据的解读方式和诊断流程。

基于深度学习的 ECG 自动诊断。心电图是诊断心脏疾病最常用的无创检查手段。传统 ECG 诊断依赖心内科医生的专业经验，不同医生之间的诊断一致性存在差异。深度卷积神经网络可以直接以 12 导联 ECG 原始波形（通常是 10 秒长度的采样数据）作为输入，端到端地输出各类心律失常的诊断结果。在一项包含超过 5 万例 ECG 的大规模研究中，基于 ResNet 的深度学习模型在 12 类心律失常的检测中达到了与资深心内科医生相当甚至更优的水平，平均 AUC 达到 0.97。在可穿戴 ECG 设备（如智能手表）中，轻量级 CNN 模型可以实时检测房颤等常见心律失常，为患者提供及时的预警。

基于强化学习的 CT 扫描参数优化。在 CT 和 MRI 等医学影像采集中，需要在图像质量、扫描时间和辐射剂量（CT）之间取得平衡。基于强化学习的方法可以自适应地优化扫描参数。以 CT 扫描为例，强化学习智能体根据当前扫描位置和前序扫描的初步重建图像质量，动态调整管电流和管电压等参数，在保证诊断所需图像质量的前提下最小化患者的辐射剂量。实验表明，基于 SAC 自适应参数优化的 CT 扫描方案可以在保持同等图像质量的情况下，将辐射剂量降低 30%-50%，这对于需要频繁复查的患者意义重大。

基于多模态 Transformer 的医学数据融合。现代医疗诊断通常需要综合考虑多种测量数据——影像、波形、实验室检验结果等。多模态 Transformer 架构可以将这些异构的测量数据融合为一个全面的诊断决策。例如，在心衰诊断中，系统同时处理心脏超声图像（通过 Vision Transformer 编码）、ECG 波形（通过时序 Transformer 编码）和血液检验指标（通过 MLP 编码），利用交叉注意力机制捕捉模态间的互补信息，最终给出综合性的诊断建议，诊断准确率显著优于仅使用单一模态数据的方法。

7.3 环境监测中的智能测量

环境监测系统需要长期、大范围、稳定地运行，面临着传感器数量庞大、部署环境恶劣、通信带宽有限、电力供应受限等挑战。AI 技术为环境监测系统的智能化运行提供了核心支撑。

基于深度学习的传感器自动校准。低成本空气质量传感器（如电化学气体传感器、光学颗粒物传感器）在长期使用中存在严重的漂移问题，传统定期人工校准成本高昂。

基于 LSTM 的传感器漂移校正模型可以学习传感器的漂移模式，利用与参考级仪器的间歇性比对数据来自动校正传感器读数。在北京某空气质量监测网络中，基于深度学习的传感器自动校准方法将低成本 PM2.5 传感器的测量误差从 $\pm 15 \mu g/m^3$ 降低到了 $\pm 3 \mu g/m^3$，使低成本传感器网络达到了接近参考级仪器的测量精度。这一技术大大降低了大规模空气质量监测网络的部署和运维成本。

基于强化学习的监测无人机路径规划。利用搭载气体传感器的无人机进行大气污染监测具有机动性强、空间分辨率高的优势。无人机的飞行路径规划直接影响监测效率和覆盖范围。基于强化学习的路径规划策略以风场预测、地形信息和已采集浓度分布为状态，以飞行方向和速度为动作，以信息增益和覆盖面积为奖励。在模拟的工业区气体泄漏监测场景中，基于强化学习的无人机路径规划相比传统的覆盖式搜索和梯度上升式搜索策略，将污染源的定位时间缩短了 40%，定位精度提升了 25%。

基于深度学习的噪声监测与声源定位。城市环境噪声监测是智慧城市的重要组成部分。基于麦克风阵列和深度学习的分布式噪声监测系统可以实现声源的自动分类和定位。将麦克风阵列采集的多通道声信号通过波束形成算法生成空间声场图，再利用 CNN 进行声源类型识别（交通噪声、施工噪声、生活噪声等），同时结合到达时间差估计实现高精度声源定位。在实际城市环境中，这种系统对主要噪声源的分类准确率达到 92% 以上，定位精度在 5 米以内。

基于图神经网络的水质监测。城市供水管网是复杂的图结构系统，各监测点的水质数据在空间上存在关联。图神经网络（GNN）能自然建模传感器节点间的拓扑关系，同时利用节点时序特征和邻居空间信息识别水质异常。相比孤立分析每个传感器数据的方法，GNN 方法将水质污染事件的误报率降低了 50%，检测延迟缩短了 30%。

7.4 通信系统中的智能信号测量

现代通信系统的复杂性——从 5G 的大规模 MIMO 波束赋形、毫米波通信到卫星通信和深空探测——给信号测量带来了巨大挑战。AI 技术在通信信号测量中的应用正在快速发展。

基于深度学习的信道估计与信号检测。在 5G 大规模 MIMO 系统中，精确的信道状态信息（CSI）对于波束赋形和信号检测至关重要。传统信道估计方法（如最小二乘估计、最小均方误差估计）在高移动性场景中性能严重下降。基于深度学习的信道估计方法——如使用 CNN 或 Transformer 直接从导频信号中估计信道矩阵——在高速移动场景中显著优于传统方法。特别是将信道估计的物理模型与深度学习相结合的模型驱动方法（如将迭代优化算法展开为神经网络层的深度展开网络），在保证估计精度的同时

具有良好的可解释性和泛化能力。

基于机器学习的频谱感知。频谱感知是认知无线电的核心技术，要求次要用户准确判断主用户信号是否存在，以避免干扰。传统频谱感知方法（如能量检测、循环平稳特征检测）在低信噪比环境中可靠性不足。基于 CNN 或 LSTM 的频谱感知方法可以自动从接收信号的 I/Q 采样、频谱图或循环谱中学习判别性特征，在信噪比低至-20dB 的环境中仍能保持 90% 以上的检测准确率，远超传统能量检测方法的表现。

基于强化学习的自适应调制编码。自适应调制编码（AMC）根据信道条件动态选择调制方式和编码速率，是提高频谱效率的关键技术。将 AMC 建模为强化学习问题：状态为信道质量指标（如信噪比估计、误码率统计），动作为调制编码方案的选择，奖励由频谱效率和误码率共同决定。基于 DQN 的自适应调制编码策略能够在不依赖信道统计模型的情况下，通过与实际通信环境的交互自主学习最优方案，在时变信道中的频谱效率相比基于固定查表的传统 AMC 方法提升了 15%-25%。

8 挑战、展望与结论

8.1 当前面临的主要挑战

尽管人工智能与电子测量的融合取得了丰富成果，从研究走向工程化应用仍面临重要挑战：

数据质量与标注瓶颈。AI 模型性能高度依赖训练数据的质量和数量。电子测量中异常和故障样本天然稀少，数据不平衡问题严重；精标注需要大量专业工程师投入，成本高昂。此外，不同传感器、不同环境下的数据分布存在差异，模型鲁棒性需持续提升。

可解释性与可信度。在医疗、核电和航空航天等安全关键领域，”黑箱”式深度学习模型难以获得充分信任。虽然 Grad-CAM、SHAP 等工具可提供一定的解释，但它们只能给出近似解释而非精确因果关系。AI 辅助系统不仅需要给出判断，还需提供判断依据和置信度。

实时性与资源约束。工业控制回路的测量延迟需控制在毫秒级，但大型深度学习模型的推理延迟仍然过高。在资源受限的嵌入式平台上，即使压缩后的轻量级模型也可能难以满足实时要求。异构计算（CPU+GPU+FPGA+NPU）和算法-硬件协同设计是解决方向。

泛化能力。在实验室训练的模型部署到不同现场时常常性能退化。传感器老化、环境变化等因素导致训练与部署数据的分布偏移，当前领域自适应方法仍不能完全解决这一问题。

安全性与对抗鲁棒性。深度学习模型易受对抗样本攻击——对输入施加微小扰动即可能导致完全错误的判断。在电子测量中，对抗攻击可能导致故障诊断系统漏报关键故障。对抗训练和认证防御是当前主要的防御策略。

标准化与互操作性。不同厂商的智能测量仪器采用不同 AI 架构和数据格式，导致”数据孤岛”问题。推动智能测量领域的标准化是实现产业规模化的必要条件。

8.2 未来发展趋势

大模型与基础模型。借鉴 GPT、BERT 的成功，测量领域有望出现自己的基础模型——在大规模多类型测量数据上预训练，学习通用信号表示和物理规律，然后通过轻量微调适配具体任务，极大降低新任务的数据需求。

物理模型驱动的智能测量。纯数据驱动方法在物理合理性方面存在隐患。神经符号 AI 将神经网络的表示学习与符号推理的逻辑严谨性结合，将物理定律融入网络架构和

训练过程，实现既强大又遵循物理规律的智能测量模型。

边缘 AI 与 TinyML。随着 TinyML 发展，在成本数美元、功耗毫瓦级的微控制器上运行 AI 推理成为现实。每个传感器都将具备本地智能处理能力，减少数据传输延迟，增强隐私保护。预计未来 5-10 年，集成 AI 的智能传感器将成为标准配置。

数字孪生。数字孪生为物理测量系统创建高保真数字镜像。AI 模型可在虚拟环境中安全试错学习，再将优化策略部署到物理系统，极大加速开发迭代，降低风险和成本。

联邦学习与隐私保护。在多机构协同测量中，联邦学习使各方在不共享原始数据的前提下协同训练模型，梯度加密和差分隐私保障数据安全，释放跨机构数据的协同价值。

自主学习与持续进化。未来系统将在运行中不断学习，自动适应环境变化，持续优化模型和策略。这需要突破" 训练-部署-退役" 的静态范式，发展终身学习和自动化机器学习技术。

8.3 结论

电子测量技术作为现代科学研究和工业生产的基础支撑技术，正站在智能化变革的关键节点。人工智能——特别是机器学习、深度学习和强化学习——为电子测量技术的智能化升级提供了强大的技术手段和全新的解决思路。

在机器学习方面，KPCA、ICA 等核方法与降维技术提升了非线性测量信号的特征提取能力，SVR 和高斯过程改善了测量误差补偿与不确定度量化的精度与可靠性，随机森林和梯度提升树在故障诊断和预测性维护中展现出优异的性能和良好的可解释性。这些成熟的机器学习方法在结构化测量数据的分析处理中发挥了重要作用，且因其相对简单的原理和较好的可解释性，在工业界得到了最广泛的应用。

在深度学习方面,CNN 在信号识别与分类中显著提升了精度和自动化水平,RNN/LSTM 在时序测量数据分析中有效捕捉了长期依赖关系，自编码器实现了灵活的信号去噪与异常检测，GAN 解决了稀缺测量数据的增强和缺失补全问题，Transformer 为长序列建模和多模态融合提供了全新的技术方案。深度学习通过其强大的自动特征学习能力，让测量系统能够处理越来越复杂的信号和环境。

在强化学习方面，自适应测量策略优化实现了功耗与精度的智能平衡，多智能体强化学习有效解决了大规模传感器网络的协同调度问题，仪器自动校准和协同测量决策展现了强化学习在序贯决策场景中的独特优势。强化学习为测量系统赋予了" 边做边学" 的能力，使其能够在不完全了解环境的情况下逐步优化测量策略。

通过工业过程、医疗诊断、环境监测和通信信号四个领域的综合应用案例，本文展示了 AI 驱动的智能测量技术在实际场景中带来的显著效果——测量精度的数量级提升、

运行效率的大幅提高、运维成本的显著降低，以及全新测量能力的实现。

展望未来，大模型与基础模型、神经符号 AI、边缘 AI、数字孪生和联邦学习等前沿技术的发展，将持续推动电子测量技术迈向更高层次的智能化。电子测量技术与人工智能的深度融合是一项长期而富有意义的工作，两者的持续融合必将催生出更多创新的测量理论、方法和仪器，为科技进步和产业发展做出重要贡献。

参考文献

[1] Goodfellow I, Bengio Y, Courville A. *Deep Learning*. MIT Press, 2016.

[2] Sutton R S, Barto A G. *Reinforcement Learning: An Introduction* (2nd ed.). MIT Press, 2018.

[3] Bishop C M. *Pattern Recognition and Machine Learning*. Springer, 2006.

[4] LeCun Y, Bengio Y, Hinton G. Deep learning. *Nature*, 2015, 521(7553): 436-444.

[5] Mnih V, Kavukcuoglu K, Silver D, et al. Human-level control through deep reinforcement learning. *Nature*, 2015, 518(7540): 529-533.

[6] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need. *Advances in Neural Information Processing Systems*, 2017, 30: 5998-6008.

[7] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition. *Proceedings of the IEEE CVPR*, 2016: 770-778.

[8] Hochreiter S, Schmidhuber J. Long short-term memory. *Neural Computation*, 1997, 9(8): 1735-1780.

[9] Kingma D P, Welling M. Auto-encoding variational Bayes. *ICLR*, 2014.

[10] Goodfellow I, Pouget-Abadie J, Mirza M, et al. Generative adversarial nets. *Advances in Neural Information Processing Systems*, 2014, 27: 2672-2680.

[11] Schulman J, Wolski F, Dhariwal P, et al. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017.

[12] Haarnoja T, Zhou A, Abbeel P, et al. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning. *ICML*, 2018: 1861-1870.

[13] Lillicrap T P, Hunt J J, Pritzel A, et al. Continuous control with deep reinforcement learning. *ICLR*, 2016.

[14] Raissi M, Perdikaris P, Karniadakis G E. Physics-informed neural networks. *Journal of Computational Physics*, 2019, 378: 686-707.

[15] Chen T, Guestrin C. XGBoost: A scalable tree boosting system. *Proceedings of ACM SIGKDD*, 2016: 785-794.

[16] Breiman L. Random forests. *Machine Learning*, 2001, 45(1): 5-32.

[17] Cortes C, Vapnik V. Support-vector networks. *Machine Learning*, 1995, 20(3): 273-297.

[18] Rasmussen C E, Williams C K I. *Gaussian Processes for Machine Learning*. MIT Press, 2006.

[19] Selvaraju R R, Cogswell M, Das A, et al. Grad-CAM: Visual explanations from deep networks via gradient-based localization. *Proceedings of IEEE ICCV*, 2017: 618-626.

[20] Lundberg S M, Lee S I. A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 2017, 30: 4765-4774.